



Plan de Trabajo e Implementación del Proyecto

Predicción de Cierre de Clientes (Churn) — Interconnect

🎯 **Objetivo General:** Construir un modelo predictivo alineado con la metodología **CRISP-DM** para identificar con anticipación a los clientes en riesgo de cancelación (*churn*) en **Interconnect**, permitiendo al equipo comercial actuar con promociones y planes de retención oportunamente.

1. Plan de Trabajo por Etapas (CRISP-DM)

Paso 1: Entendimiento del Negocio (*Business Understanding*)

- 🎯 **Objetivo Comercial:** Reducir la tasa de cancelación de clientes mediante la identificación temprana de usuarios en riesgo.
- 📊 **Métrica Clave:** Maximizar el **Recall** y el **F1-Score** (o AUC-ROC). Es crucial capturar la mayor cantidad de clientes que se irán (*falsos negativos mínimos*) para ofrecerles incentivos de retención.
- 🏆 **Criterio de Éxito:** Desarrollar un modelo que supere sustancialmente al *baseline* en F1-Score y genere un retorno de inversión (ROI) positivo en las campañas de fidelización.

Paso 2: Entendimiento de los Datos (*Data Understanding*)

- 📁 **Unificación de Datasets:** Inspeccionar y vincular las 4 fuentes mediante la llave primaria `customerID`:
 - 📄 `contract.csv`: Tipo de contrato, métodos de pago, facturación electrónica, cargos mensuales/totales y fechas clave.
 - 👤 `personal.csv`: Perfil demográfico del cliente.
 - 🌐 `internet.csv`: Tipo de conexión (DSL/Fibra óptica) y servicios adicionales (seguridad, backup, soporte, streaming).
 - 📞 `phone.csv`: Uso del servicio telefónico y líneas múltiples.
- 🔍 **Análisis Exploratorio (EDA):**
 - Detectar valores ausentes, tipos de datos incorrectos y posibles *outliers*.
 - Evaluar el desbalance de la variable objetivo (usuarios activos vs. cancelados).
 - Generar gráficas descriptivas para identificar patrones iniciales de pérdida de clientes.

Paso 3: Preparación de Datos (*Data Preparation*)

- 🎯 **Definición de la Variable Objetivo (Target):** Crear la columna binaria (1 = cliente canceló, 0 = cliente activo).
- 🔗 **Combinación y Limpieza:** Realizar un *Outer/Left Join* sobre `customerID` y manejar nulos (ej. clientes sin servicio de internet o telefonía). Convertir tipos de datos (como transformar cargos totales a valor numérico y fechas a formato `datetime`).
- ⚙️ **Ingeniería de Características (*Feature Engineering*):**
 - ⌚ **Antigüedad (Tenure):** Calcular los meses/días de permanencia activa del usuario.

- 🧩 **Total de servicios:** Sumar los complementos digitales contratados (seguridad, soporte, streaming).
- 💰 **Relación de costos:** Calcular la proporción entre los cargos mensuales y el costo acumulado.
- 🏷️ **Codificación y Escalamiento:** Aplicar *One-Hot Encoding* o *Ordinal Encoding* a las variables categóricas. Normalizar/escalar las variables continuas numéricas mediante `StandardScaler` o `RobustScaler`.
- ✂️ **División del Dataset:** Realizar la división en Entrenamiento y Prueba (*Train/Test Split*) de forma estratificada (`stratify=y`) y fijar `random_state=42`.

🤖 Paso 4: Modelado (*Modeling*)

- 📌 **Modelo Base (*Baseline*):** Entrenar un algoritmo simple (ej. *Logistic Regression*) para marcar la métrica de referencia inicial.
- 🌲 **Modelos Avanzados / Ensembles:**
 - *Random Forest Classifier*.
 - Algoritmos de Gradient Boosting (*XGBoost*, *LightGBM* o *CatBoost*).
- 🛠️ **Ajuste de Hiperparámetros:** Utilizar `GridSearchCV` o `RandomizedSearchCV` acompañado de Validación Cruzada (*K-Fold*) para evitar el sobreajuste (*overfitting*).

📈 Paso 5: Evaluación y Diagnóstico (*Evaluation*)

- 📋 **Comparativa:** Comparar modelos con las métricas **F1-Score**, **Recall**, **Precision**, **Accuracy** y **AUC-ROC**.
- 🧩 **Diagnóstico:** Analizar la Matriz de Confusión y extraer la Importancia de Características (*Feature Importance*) para explicar al negocio los factores de mayor riesgo en la fuga de clientes.

💻 2. Guía para el Código de Solución (Etapa 2)

Al construir tu cuaderno Jupyter, mantén las siguientes prácticas de calidad de código e interpretabilidad:

- 🎲 **Reproducibilidad Total:** Fijar la semilla de aleatoriedad desde el inicio:

```
import numpy as np
import random

SEED = 42
np.random.seed(SEED)
random.seed(SEED)
```

- 📦 **Código Modular y Limpio:** Encapsular los procesos de limpieza, transformación e inferencia en funciones reutilizables documentadas con *docstrings*.
- 📊 **Visualizaciones Claras:** Incluir títulos, ejes identificados y leyendas en cada gráfica desarrollada.
- 📝 **Registro de Experimentos:** Mantener una tabla comparativa de resultados para evidenciar las mejoras entre el *baseline* y los modelos avanzados.



3. Estructura Sugerida para el Informe de Solución (Etapa 3)

El reporte final debe estar organizado con los siguientes apartados clave para la toma de decisiones directivas:



1. Resumen Ejecutivo

Antecedentes del problema de negocio y metas estratégicas de Interconnect. Breve síntesis del modelo seleccionado y su desempeño clave.



2. Hallazgos Principales del EDA

Identificación de los perfiles con mayor propensión al retiro (ej. tipo de contrato, uso de fibra óptica sin servicios de seguridad).



3. Resultados del Modelo Predictivo

Tabla comparativa con la evolución de métricas por experimento (*Baseline* vs. *Ensembles*). Gráficas de Matriz de Confusión e Importancia de Variables (*Feature Importance*).



4. Limitaciones del Proyecto

Consideraciones sobre la disponibilidad de datos (ej. ausencia de historial de soporte técnico o reclamaciones).



5. Recomendaciones de Negocio

Propuestas accionables para el área de marketing y retención (ofertas cruzadas en servicios de seguridad, promociones de migración a contratos anuales, etc.).