



Plan de Trabajo: Predicción de Cancelación de Clientes (Churn)

Ciente: Operador de Telecomunicaciones Interconnect | Metodología: CRISP-DM / Framework Agile

PROYECTO FINAL

1. Entendimiento del Negocio (Business Understanding)

1.1 Objetivo del Proyecto

El operador de telecomunicaciones **Interconnect** busca predecir de forma anticipada los clientes con alto riesgo de cancelar sus servicios (*churn*). La meta estratégica es identificar a estos usuarios antes de que rescindan su contrato para ofrecerles incentivos de retención personalizados (códigos promocionales, promociones exclusivas y planes de suscripción ajustados).

1.2 Pregunta Guía de Negocio

"¿Qué patrones socio-demográficos, de contratación y de uso de servicios caracterizan a los clientes propensos a abandonar el servicio, y cómo podemos clasificarlos de manera precisa con machine learning para maximizar la retención?"

1.3 Métrica Principal de Éxito Técnica y de Negocio

- **Métrica Principal: AUC-ROC** (métrica objetivo requerida ≥ 0.85 para alta capacidad discriminativa).
- **Métricas Secundarias:**
 - **Recall / Sensibilidad:** Priorizar capturar la mayor cantidad posible de clientes que realmente se darán de baja (minimizar falsos negativos).
 - **F1-Score:** Garantizar un balance sólido entre Precisión y Recall.
 - **Accuracy:** Evaluación general de exactitud del modelo.

2. Entendimiento de los Datos (Data Understanding)

Se cuenta con cuatro fuentes primarias conectadas mediante la clave única `customerID`:

Archivo	Filas	Variables Clave
<code>contract.csv</code>	7,043	<code>BeginDate</code> , <code>EndDate</code> , <code>Type</code> , <code>PaperlessBilling</code> , <code>PaymentMethod</code> , <code>MonthlyCharges</code> , <code>TotalCharges</code>
<code>personal.csv</code>	7,043	<code>gender</code> , <code>SeniorCitizen</code> , <code>Partner</code> , <code>Dependents</code>
<code>internet.csv</code>	5,517	<code>InternetService</code> , <code>OnlineSecurity</code> , <code>OnlineBackup</code> , <code>DeviceProtection</code> , <code>TechSupport</code> , <code>StreamingTV</code> , <code>StreamingMovies</code>
<code>phone.csv</code>	6,361	<code>MultipleLines</code>

2.1 Tareas de Análisis Exploratorio Inicial (EDA)

- **Unión de Fuentes (Data Merging):** Realizar un `LEFT JOIN` a partir del archivo principal `contract.csv` usando `customerID`.
- **Definición de la Variable Objetivo (Target):** La columna `EndDate` define si el cliente está activo (No) o si se dio de baja (fecha explícita, ej. 2019-10-01). Crear la variable binaria `target`: 0 para activo, 1 para cancelado (*churn*).
- **Identificación de Calidad y Discrepancias de Datos:** Detectar valores faltantes implícitos en `internet.csv` y `phone.csv`. Revisión de tipos de datos (conversión de `TotalCharges` a float y fechas) y detección del desbalance de clases.

3. Preparación e Ingeniería de Características (Data Prep & Feature Engineering)

3.1 Limpieza y Preprocesamiento

- **Tratamiento de Nulos por Ausencia de Servicio:** Rellenar vacíos en `internet.csv` con 'No internet' y en `phone.csv` con 'No phone'.
- **Corrección de Tipos de Datos:** Formatear `TotalCharges` a numérico (imputar clientes nuevos con 0 o `MonthlyCharges`) y convertir `BeginDate` a `datetime`.

3.2 Feature Engineering (Creación de Variables Clave)

- **Antigüedad del Cliente (`tenure_days` / `tenure_months`):** Días/meses transcurridos entre `BeginDate` y `EndDate` (o fecha tope `2020-02-01` si está activo).
- **Servicios Totales Contratados (`total_services`):** Conteo agregado de servicios adicionales contratados (seguridad, backup, soporte técnico, streaming, etc.).
- **Indicador de Contratación Combo (`has_both_services`):** Flag que indica si cuenta con telefonía e internet simultáneamente.
- **Relación de Cargos (`charge_ratio`):** Proporción entre `TotalCharges` y `tenure_days` o comparación de tarifa mensual vs. promedio.

3.3 Codificación y Escalamiento

- **One-Hot / Ordinal Encoding:** Aplicar a variables categóricas (`Type`, `PaymentMethod`, `InternetService`).
- **StandardScaler / MinMax:** Aplicar a variables continuas (`MonthlyCharges`, `TotalCharges`, `tenure_days`).

4. Modelado y Experimentación (Modeling)

4.1 Estrategia de Validación

- **Estratificación del Dataset:** División Train/Test (80% / 20%) con `stratify=target` y semilla fija `random_state=42`.
- **Validación Cruzada:** Estratificada (K=5 folds) sobre entrenamiento para optimización de hiperparámetros.

4.2 Progresión de Modelos

 [01. Baseline / Regla Simple] →  [02. Regresión Logística / Árbol] →  [03. Random Forest] →  [04. Gradient Boosting]

- **Baseline:** Clasificador aleatorio o constante para fijar el umbral mínimo.
- **Modelos Lineales y Árboles:** `LogisticRegression` y `DecisionTreeClassifier` para interpretación inicial.
- **Ensamblados:** `RandomForestClassifier`.
- **Gradient Boosting Ajustados:** `CatBoostClassifier`, `LGBMClassifier` y `XGBoostClassifier` con tuning vía `GridSearchCV`.

5. Evaluación y Diagnóstico (Evaluation)

- **Evaluación de Métricas en Test:** Curva ROC y cálculo de **AUC-ROC** (≥ 0.85), Matriz de Confusión, Precision, Recall y F1-Score.
- **Importancia de Características (Feature Importance / SHAP values):** Identificar las variables de mayor impacto en la fuga (tipo de contrato, fibra óptica, antigüedad corta).
- **Análisis de Umbral (Threshold Tuning):** Ajustar el umbral de probabilidad para optimizar el balance costo-beneficio del envío de campañas promocionales.

6. Estructura del Repositorio (Estructura Estándar CRISP-DM)

```
proyecto_final_interconnect/  
├── README.md           <-- Descripción general del proyecto y métricas  
├── requirements.txt     <-- Librerías con versiones exactas  
├── data/  
│   ├── raw/           <-- Archivos CSV originales (intocables)  
│   └── processed/      <-- Dataset limpio y procesado  
├── notebooks/  
│   ├── 01_eda_and_data_prep.ipynb <-- Exploración, fusión y limpieza  
│   ├── 02_feature_engineering.ipynb <-- Creación de variables y codificación  
│   └── 03_model_training.ipynb    <-- Entrenamiento, tuning y evaluación  
├── src/  
│   ├── data_cleaning.py    <-- Funciones modulares de limpieza  
│   └── evaluation.py       <-- Funciones modulares para métricas y gráficas  
└── reports/  
    └── informe_de_solucion.pdf <-- Informe ejecutivo final
```

7. Cronograma Ejecutivo de Trabajo

Fase	Tarea Principal	Entregable Clave
Fase 1: Plan de Trabajo	Análisis del contexto de negocio, exploración inicial y elaboración del plan.	Documento formal de Plan de Trabajo approved.
Fase 2: Código de Solución	Fusión de datos, limpieza, feature engineering, entrenamiento con validación cruzada y tuning.	Repositorio estructurado y Notebooks ejecutables (Run All).
Fase 3: Informe de Solución	Síntesis de resultados, hallazgos de negocio, limitaciones, conclusiones y recomendaciones.	Informe final de solución estratégico para stakeholders.